

Image Retrieval

BOW, VLAD, FV

字节跳动人工智能实验室 杨成

GitHub: <https://github.com/ironyoung>

BOW

- Bag of Words. Based on clustering (聚类)
- 聚类方法汇总
 - Partitioning: 建立数据分割, 相同标准评价聚类结果
 - Model-based: 假设分布模型, 寻找最优分布
 - Reduction: 先降维, 再聚类

BOW - Partitioning

- eg. kmeans
- Kmeans 目的：把 N 个点（可以是样本的一次观察或一个实例）划分到 k 个聚类中，使每个点都属于离他最近的聚类中心

$$\arg \min_S \sum_{k=1}^K \sum_{\mathbf{x} \in S_k} \| \mathbf{x} - \boldsymbol{\mu}_k \|^2$$

- Kmeans 算法步骤：
 - 分配 (Assignment)：将每个观测点分配到聚类中，使组内平方和最小。所以把观测点分配到离它最近得均值点即可。尽管理论上可能分配到多个聚类
 - 更新(Update)：对上一步得到的每个聚类，以聚类中观测值图心作为新的均值点

BOW - Partitioning



- Kmeans in image retrieval:
 - 提取 local descriptor (SIFT, SURF ...)
 - descriptor kmeans
 - image -> descriptors -> centroids = words

BOW - Partitioning

- Kmeans Tricks:
 - 多中心聚类 (权重分配)
 - 多次随机初始点
 - 分段聚类

BOW - Model-based

- eg. GMM (Gaussian mixture model)



- k 个高斯模型混合在一起，每个点出现的概率是若干个高斯模型混合的结果

- 多元正态分布的概率密度函数

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

↑标准差
 ↑平均值

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^d |\boldsymbol{\Sigma}|}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})\right)$$

↑多元维度
 ↑协方差矩阵
 ↑均值向量

- 记 $\mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma}) = f_{\mathbf{x}}(\mathbf{x})$ ，则 GMM 概率密度函数为 $p(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) = \sum_{k=1}^K w_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$
- 高斯模型个数，又称 Component 个数
 ↓
 K
 高斯分布权重 $\sum_{k=1}^K w_k = 1$

BOW - Model-based

- 假定数据由 GMM 生成出来，则根据数据推导出 GMM 的概率分布（已知结果，反推先验模型），GMM 的 K 个 Component 对应 K 个 cluster
- 已知：概率密度函数形式（GMM, $p(\mathbf{x})$ ）；“推导”参数的过程：参数估计
- 哪些参数需要估计？ $\theta = w, \mu, \Sigma$
- 参数估计的方法？最大化似然函数
- 什么是似然函数？对 N 个观察（ $\mathbf{x}_1 \dots \mathbf{x}_n$ ）而言，似然函数

$$L(\theta | \mathbf{x}_1 \dots \mathbf{x}_n) = p(\mathbf{x}_1 \dots \mathbf{x}_n | \theta) = \prod_{n=1}^N p(\mathbf{x}_n | \theta)$$

BOW - Model-based

- 最大化似然函数 $L(\theta | \mathbf{x}_1 \dots \mathbf{x}_n) = p(\mathbf{x}_1 \dots \mathbf{x}_n | \theta) = \prod_{n=1}^N p(\mathbf{x}_n | \theta)$

- 浮点数下溢，所以使用对数形式

$$\log L(\theta | \mathbf{x}_1 \dots \mathbf{x}_n) = \log \left(\prod_{n=1}^N p(\mathbf{x}_n | \theta) \right) = \sum_{n=1}^N \log \left(\sum_{k=1}^K w_k \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right)$$

- 求解参数方法
 - 最大化 $\arg \max L(\theta | \mathbf{x}_1 \dots \mathbf{x}_n)$: 求导 / 偏导求极值
 - 多参数 $\theta = w, \mu, \Sigma$: EM 算法

BOW - Model-based

- 似然函数 $\log L(\theta | \mathbf{x}_1 \dots \mathbf{x}_n) = \sum_{n=1}^N \log \left(\sum_{k=1}^K w_k \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right)$

- 似然函数对 μ_k 求偏导，并令其极值 = 0，可得


$$-\sum_{n=1}^N \frac{w_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_i^K w_i \mathcal{N}(\mathbf{x}_n | \mu_i, \Sigma_i)} \Sigma_k (\mathbf{x}_n - \mu_k) = 0$$

$= \gamma(n, k) \Rightarrow \text{clustering}$

- 记 $N_k = \sum_{n=1}^N \gamma(n, k)$ ，上式化简后得 $\mu_k := \frac{1}{N_k} \sum_{n=1}^N \gamma(n, k) \mathbf{x}_n$

- 同理，对 Σ_k, w_k 分别求偏导数，化简得到

- $\Sigma_k := \frac{1}{N_k} \sum_{n=1}^N \gamma(n, k) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T$ $w_k := \frac{N_k}{N}$



BOW - Model-based

- EM 算法步骤 $\arg \max \sum_{n=1}^N \log \left(\sum_{k=1}^K w_k \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right)$
- Initialization (Kmeans 初始化 GMM) : $\theta = \mathbf{w}, \boldsymbol{\mu}, \boldsymbol{\Sigma}$
- E step: $\mathbf{w}, \boldsymbol{\mu}, \boldsymbol{\Sigma} \Rightarrow \gamma$
- M step: $\gamma \Rightarrow \mathbf{w}^{new}, \boldsymbol{\mu}^{new}$
 $\gamma, \boldsymbol{\mu}^{new} \Rightarrow \boldsymbol{\Sigma}^{new}$
- Evaluation: evaluate log likelihood, may return to E step

BOW - Reduction

- 首先 dimensionality reduction: PCA, random projection, ...
- 继续 clustering

VLAD

- 不定长特征样本 (eg. SIFT) -> 定长特征

- $$v_k = \sum_{\mathbf{x} \in S_k} (\mathbf{x} - \mathbf{c}_k)$$

第 k 类聚类中心

可以归属于多个类，权重分配

Fisher Vector

- FV 本质是用似然函数的梯度向量表示一副图像

$$\log L(\theta | \mathbf{x}_1 \dots \mathbf{x}_n) = \log \left(\prod_{n=1}^N p(\mathbf{x}_n | \theta) \right) = \sum_{n=1}^N \log p(\mathbf{x}_n | \theta)$$

- 各求梯度, FV 维度 $(1+2D)*K - 1$ $\sum_{k=1}^K w_k = 1$, 各个分量为:

$$\frac{\partial L(\mathbf{x} | \theta)}{\partial w_k} = \sum_{n=1}^N \left[\frac{\gamma(k, n)}{w_k} - \frac{\gamma(k, 1)}{w_1} \right]$$

$$\frac{\partial L(\mathbf{x} | \theta)}{\partial \mu_k^d} = \sum_{n=1}^N \gamma(k, n) \left[\frac{x_k^d - \mu_k^d}{(\sigma_k^d)^2} \right]$$

- $$\frac{\partial L(\mathbf{x} | \theta)}{\partial \sigma_k^d} = \sum_{n=1}^N \gamma(k, n) \left[\frac{(x_k^d - \mu_k^d)^2}{(\sigma_k^d)^3} - \frac{1}{\sigma_k^d} \right]$$

Fisher Vector

- 生成式模型关注类条件概率的建模，学 $p(X, Y) \xrightarrow{\text{Bayes}} p(Y|X)$
- 判别式模型则直接关注问题的本身，直接学习 $p(Y|X)$
- FV 是一个生成模型，但是得到 FV 之后接入的分类器是判别式模型，依赖于归一化后的向量
- 如何对于 FV 归一化呢？

Fisher Vector

- Fisher Vector 归一化 (概率空间) $G_{\theta}^{\mathbf{x}} = \frac{\partial \log p(\mathbf{x} | \theta)}{\partial \theta}$
- FIM (Fisher Information Vector) $F_{\theta} = E_{\mathbf{x}} [(G_{\theta}^{\mathbf{x}})^2]$
- 归一化后梯度向量 $G_{\theta}^{\mathbf{x}} = F_{\theta}^{-1/2} G_{\theta}^{\mathbf{x}}$
- FIM 一般求近似解


Fisher Vector

- FIM 归一化后的梯度向量

$$f_{w_i} = K\left(\frac{1}{w_i} + \frac{1}{w_1}\right)$$

$$f_{\mu_i^d} = K \frac{w_i}{(\sigma_i^d)^2}$$

$$f_{\sigma_i^d} = K \frac{2w_i}{(\sigma_i^d)^2}$$



$$\mathcal{G}_{w_k} = f_{w_i}^{-1/2} \frac{\partial L(\mathbf{x} | \theta)}{\partial w_k}$$

$$\mathcal{G}_{\mu_k^d} = f_{\mu_i^d}^{-1/2} \frac{\partial L(\mathbf{x} | \theta)}{\partial \mu_k^d}$$

$$\mathcal{G}_{\sigma_k^d} = f_{\sigma_i^d}^{-1/2} \frac{\partial L(\mathbf{x} | \theta)}{\partial \sigma_k^d}$$

- concatenate 组成 Fisher Vector \mathcal{G} ，再进行 \mathcal{L}_2 正则化

Reference

- 聚类算法分类: <https://blog.csdn.net/abcjennifer/article/details/8170687>
- 最大似然、EM 算法
 - <https://blog.csdn.net/zouxy09/article/details/8537620>
 - <https://vividfree.github.io/docs/2016-08-19-introduction-about-EM-algorithm-doc1.pdf>
- GMM: <https://blog.csdn.net/abcjennifer/article/details/8198352>
- VLAD: [Aggregating local descriptors into a compact image representation](#)
- Fisher Vector
 - Fisher Information: <https://www.zhihu.com/question/26561604>
 - [Image Classification with the Fisher Vector: Theory and Practice](#)
 - Fisher Kernel: [Fisher Kernels on Visual Vocabularies for Image Categorization](#)